

Fundamentos de Machine Learning

O que é Machine Learning

Machine Learning (Aprendizagem de Máquina) é uma área da Inteligência Artificial que cria modelos capazes de aprender padrões a partir de dados históricos para realizar previsões ou tomar decisões.

Um modelo é uma representação matemática dos relacionamentos existentes nos dados.

Conceitos Fundamentais

Instâncias ou Observações

São as linhas de um conjunto de dados (dataset).

Variável Resposta (Target)

É a variável que o modelo deseja prever.

Também pode ser chamada de:

- classe
- label
- variável dependente

Features

São os atributos utilizados para prever a variável target.

Também podem ser chamadas de:

- atributos
 - variáveis explicativas
 - variáveis independentes
-

Tipos de Aprendizagem em Machine Learning

Os algoritmos de Machine Learning são divididos principalmente em:

- Aprendizagem Supervisionada
 - Aprendizagem Não Supervisionada
-

Aprendizagem Supervisionada

Na aprendizagem supervisionada, o algoritmo aprende utilizando dados de entrada e suas respectivas respostas corretas.

Os dados precisam estar rotulados.

Esse tipo de aprendizagem é utilizado principalmente em:

- classificação
- regressão

Classificação

Produz resultados categóricos.

Exemplo:

- aprovado/reprovado
- spam/não spam

Regressão

Produz valores numéricos contínuos.

Exemplo:

- previsão de nota
 - previsão de preço
-

Regressão Linear

A regressão linear busca prever valores numéricos através de uma relação linear entre variáveis.

A fórmula básica é:

$$y = Wx + B$$

www

bbb

Onde:

- W representa o peso (weight)
- B representa o bias

O treinamento consiste em encontrar os melhores valores para W e B.

Exemplo:

Prever a nota final de estudantes utilizando:

- horas de estudo
 - quantidade de faltas
-

K-Nearest Neighbors (KNN)

KNN é um algoritmo de classificação baseado nos vizinhos mais próximos.

Quando um novo dado é apresentado, o algoritmo verifica os exemplos mais próximos para definir sua classe.

O parâmetro k representa a quantidade de vizinhos analisados.

Exemplo:

Se a maioria dos vizinhos pertence à classe “triângulo”, o novo elemento também será classificado como “triângulo”.

Árvore de Decisão

Árvore de decisão é uma estrutura utilizada para tomada de decisões baseada em regras.

Ela possui:

- nós
- ramos
- folhas

Os nós representam variáveis, os ramos representam decisões possíveis e as folhas representam o resultado final.

É muito utilizada para:

- classificação
 - análise de decisões
 - sistemas especialistas
-

Aprendizagem Não Supervisionada

Na aprendizagem não supervisionada, os dados não possuem respostas corretas.

O algoritmo tenta encontrar padrões e similaridades automaticamente.

É utilizada principalmente em:

- agrupamento (clustering)
 - associação
 - detecção de anomalias
-

K-Means

K-Means é um algoritmo de agrupamento (clustering).

Seu objetivo é dividir os dados em grupos semelhantes chamados clusters.

Cada cluster possui um centro chamado centroide.

Características:

- dados do mesmo grupo são semelhantes
- grupos diferentes possuem características diferentes

O número k representa a quantidade de clusters desejados.

Outros Algoritmos de Machine Learning

Algoritmos Supervisionados

- Logistic Regression
- KNN
- Naive Bayes
- Decision Trees
- Linear Regression
- Neural Networks
- Random Forest
- Support Vector Machines

Algoritmos Não Supervisionados

- K-Means

- DBSCAN
 - PCA
 - Association Rules
-

Construção de Modelos Preditivos

A construção de um modelo de Machine Learning normalmente envolve quatro etapas:

1. Pré-processamento
 2. Treinamento
 3. Avaliação
 4. Predição
-

Pré-processamento dos Dados

O pré-processamento melhora a qualidade dos dados antes do treinamento.

Principais técnicas:

Feature Selection

Seleciona os atributos mais relevantes.

Feature Engineering

Cria novas variáveis para melhorar o modelo.

Normalização

Padroniza variáveis em uma mesma escala.

Redução de Dimensionalidade

Reduz a quantidade de atributos do dataset.

Divisão Treino/Teste

Os dados são separados em:

- treino
- teste

Os dados de treino criam o modelo e os dados de teste avaliam seu desempenho.

Treinamento do Modelo

Durante o treinamento, o algoritmo aprende padrões presentes nos dados.

Cross Validation

Técnica que alterna dados de treino e teste para melhorar a avaliação do modelo.

Métricas de Desempenho

Avaliam a qualidade do modelo.

Exemplo:

- acurácia

Otimização de Hiperparâmetros

Busca os melhores parâmetros para melhorar a performance do algoritmo.

Avaliação do Modelo

O modelo recebe dados de teste e realiza previsões.

As previsões são comparadas com os resultados corretos para medir desempenho.

Predição

Após validado, o modelo pode ser utilizado para realizar previsões em novos dados.