

Regressão Logística

Introdução

A regressão logística é um método estatístico utilizado para modelar variáveis categóricas, especialmente variáveis binárias, ou seja, que possuem apenas dois resultados possíveis.

Exemplos:

- sim ou não
- aprovado ou reprovado
- possui crédito ou não possui crédito

Nesse modelo, a variável resposta normalmente é representada por valores:

- 1 → ocorrência do evento
- 0 → não ocorrência do evento

Exemplo:

- 1 → pessoa obteve crédito
- 0 → pessoa não obteve crédito

A regressão logística estima a probabilidade de ocorrência de um evento com base em variáveis explicativas.

Distribuição de Bernoulli e Binomial

Cada observação da variável resposta segue uma distribuição de Bernoulli, utilizada em eventos com apenas dois resultados possíveis.

A soma de várias observações segue uma distribuição Binomial.

O modelo busca estimar a probabilidade de sucesso do evento.

Função Logística

A regressão logística utiliza o logaritmo da razão entre:

- probabilidade de sucesso
- probabilidade de fracasso

Essa razão é chamada de logit.

O modelo relaciona variáveis explicativas com a probabilidade do evento ocorrer.

A função logística é representada por:

$$\log(p/(1-p)) = \beta_0 + \beta_1 * x_1 + \beta_2 * x_2 + \dots + \beta_k * x_k$$

Onde:

- $p \rightarrow$ probabilidade do evento ocorrer
 - $\beta \rightarrow$ coeficientes do modelo
 - $x \rightarrow$ variáveis explicativas
-

Objetivo da Regressão Logística

O principal objetivo é identificar quais variáveis influenciam a ocorrência de um evento.

O modelo permite:

- prever probabilidades
 - analisar fatores importantes
 - medir riscos
 - interpretar vantagens e desvantagens entre grupos
-

Aprendizagem Supervisionada

A regressão logística é um algoritmo de aprendizagem supervisionada.

Características:

- utiliza dados rotulados
- possui variável resposta conhecida
- é usada principalmente para classificação

Exemplos:

- detectar fraude
 - prever inadimplência
 - classificar e-mails como spam
 - prever aprovação de crédito
-

Exemplo de Aplicação

O texto apresenta um estudo sobre mobilidade ocupacional.

Objetivo:

analisar as chances de pessoas desempregadas conseguirem emprego entre 1991 e 1996.

Variável resposta:

- 1 → desempregado em 1991 e empregado em 1996
- 0 → desempregado em 1991 e desempregado em 1996

Variáveis analisadas:

- idade
 - região
 - sindicalização
 - sexo
 - raça
-

Interpretação dos Resultados

Os coeficientes da regressão logística indicam aumento ou redução das chances do evento ocorrer.

Exemplos encontrados:

- moradores do Rio de Janeiro apresentaram maiores chances de sair do desemprego em comparação com São Paulo
- pessoas sindicalizadas apresentaram maior vantagem na obtenção de emprego
- indivíduos entre 30 e 44 anos tiveram maiores chances de conseguir ocupação

A regressão logística utiliza a chamada razão de chances (odds ratio) para interpretar os resultados.

Modelo Logit Multinomial

Quando a variável resposta possui mais de duas categorias, utiliza-se o modelo logit multinomial.

Exemplos:

- empregado
- desempregado
- autônomo

Características:

- trabalha com variáveis categóricas não ordenadas
- compara categorias utilizando uma categoria base
- é uma extensão da regressão logística binária

Aplicações:

- pesquisas sociais
- economia
- política

- mobilidade ocupacional
-

Principais Aplicações da Regressão Logística

A regressão logística é muito utilizada em:

- análise de crédito
 - medicina
 - marketing
 - ciências sociais
 - previsão de risco
 - classificação de dados
 - machine learning
-

Vantagens da Regressão Logística

- fácil interpretação
 - boa para classificação binária
 - calcula probabilidades
 - permite identificar variáveis importantes
 - bastante utilizada em Machine Learning
-

Limitações

- assume relação logística entre variáveis
 - pode ter desempenho inferior em problemas muito complexos
 - sensível à qualidade dos dados
 - depende de bom pré-processamento
-

Considerações Finais

A regressão logística é um dos métodos mais importantes da estatística e do Machine Learning para problemas de classificação.

Ela permite prever probabilidades e entender como diferentes variáveis influenciam a ocorrência de eventos, sendo amplamente aplicada em áreas como finanças, saúde, economia e inteligência artificial.

